

TP manipulation de données

Le but de ce TP est de constituer un jeu de données en vue de son analyse ultérieure. On suppose ici qu'on part d'un ensemble de données existantes sous forme de fichiers csv et txt que l'on va transformer et enrichir (ici par de la génération aléatoire de données). Le résultat de ces transformations sera une base de données composée de plusieurs relations chargées sous MySQL (ou sqlite). A partir de là, on va pouvoir faire un certain nombre de manipulations comme interroger la base via SQL (permet de faire du filtrage et des calculs simples), découvrir et nettoyer les données, visualiser les données.

Première étape : construction du jeu de données

Les données initiales sont fournies dans une archive constituée de plusieurs fichiers txt et csv (les fichiers .txt proviennent de <https://base-donnees-publique.medicaments.gouv.fr/telechargement> et le csv de <https://www.kaggle.com/datasets/datarspectrum/healthcare-data-csv>) :

- CIS_bdpm.txt : contient la liste des médicaments commercialisés ou en arrêt de commercialisation depuis moins de 2 ans ;
- CIS_CIP.txt : contient les différentes présentations (packaging) des médicaments avec notamment la tarification ;
- CIS_COMPO.txt : contient la composition des médicaments (principales substances actives) ;
- CIS_GENER.txt : définit les groupes génériques de médicaments avec la liste des médicaments de ces groupes ;
- Healthcare_data.csv: donne une liste de patients.

A noter que les certains fichiers txt contiennent des attributs multivalués, par exemple les laboratoires titulaires de la licence d'un médicament) et donc ne peuvent être directement interprétés comme des relations. D'autre part d'autres fichiers (CIS_COMPO et CIS_GENER) ont des redondances qui obligent à les interpréter dans plusieurs relations. Les encodages de ces fichiers ne sont pas toujours les même, donc faire attention lors du chargement à choisir le bon encodage si on veut gérer correctement les accents. La première ligne des fichiers contient le nom des attributs. Les fichiers txt ont un séparateur qui est la tabulation (\t) alors que le fichier csv ont un séparateur qui est le point virgule (;).

Le fichier description_fichiers.pdf décrit la structure de chaque fichier ainsi que les liens entre les différents fichiers (à lire attentivement).

On veut intégrer ces différentes données (après plusieurs transformations) dans un schéma décrivant les médicaments (relation Médicaments), des laboratoires pharmaceutiques (relation Laboratoires), des substances actives (relation Substances), des groupes génériques (relation Groupes) et des présentations (relation Présentations). De plus on ajoute une relation Patients. Ce schéma n'est pas complet et doit être complété par les relations (ou attribut) représentant les associations entre ces relations (par exemple l'association liant Médicaments et Patients en considérant qu'un patient peut prendre plusieurs médicaments). Le schéma cible est décrit comme suit :

Les clés sont soulignées.

Patients(idfPatient, prenom, nom, age, genre, mail)

Médicaments(idfMedic, denomination, forme, statutAMM, dateAMM, noautorisation)

Présentations(idfPresentation, libelle, statutADM, dateCom, tauxRembt, prixMedic, prixPublic) avec idfPresentation qui correspond à codeCIP7 du fichier CIS_CIP.txt

Substances(idfSubstance, denomination, dosage, refDosage)

Groupes(idfGroupe, libelle)

Travail à faire

- 1- Etudier les données fournies (par exemple via python) puis les charger dans mysql/sqlite en utilisant phpmyadmin/sqlitestudio. Regardez également via SQL la cohérence des données entre les différentes tables (par exemple est ce que tous les médicaments ont une composition, ...)
- 2- Faire la rétroconception du schéma relationnel cible et produire son modèle conceptuel de données en utilisant un outil type looping-mcd (<https://www.looping-mcd.fr/>). Le compléter en ajoutant les associations manquantes entre les différentes entités (ne pas oublier les attributs de ces associations si besoin, ni les cardinalités).
- 3- Générer le schéma relationnel SQL à votre modèle conceptuel de données et exécutez le dans phpmyadmin/sqlitesudio.
- 4- Définissez les règles de correspondance entre les fichiers initiaux et les relations du schéma relationnel cible. A partir de celle-ci, vous en déduirez les règles de chargement des données et pour chacune de ses règles vous direz si elle peut être codée en SQL ou si elle nécessite du code python. On va charger les données dans le schéma cible à partir des données du schéma initial. Pour l'association entre Médicaments et Patients, les données sont manquantes et on va générer aléatoirement des données en prenant pour chaque patient entre 1 et 10 médicaments, en associant une date prise entre le 1/1/2025 et aujourd'hui, une posologie comprise entre 1 et 5 et une durée de 1 à 30.
- 5- Chargez les données dans le schéma cible en exécutant les règles de chargement. Vérifiez que le résultat soit correct.
- 6- Pensez à finaliser le schéma si besoin en ajoutant clés primaires et étrangères.

Deuxième étape : exploiter le jeu de données

Travail à faire

- 1- Ecrire 10 requêtes SQL permettant d'avoir des statistiques sur les données (dont au moins 6 avec des group by)
- 2- Utiliser pandas_profiling (ou tout autre bibliothèque python type ydata_profiling) pour analyser les données après intégration

Livrables à rendre

- Rétroconception du schéma cible en incluant les associations à ajouter
- Code SQL correspondant aux tables de votre schéma cible
- Fichier texte donnant les règles de correspondance entre les fichiers initiaux et le schéma cible ainsi que le code des règles de chargement des données (SQL ou python)
- Preuve que les données ont bien été chargées dans le schéma cible (count(*) sur les relations)
- Code SQL ajoutant les contraintes d'intégrité (clé primaires, étrangères, contraintes de domaine)
- Fichier texte donnant 10 requêtes SQL et un exemple de leur résultat
- Fichier texte donnant l'analyse faite sur les données après intégration